

ProcureWatch Analytics: Plataforma Multiagente para la Detección de Patrones de Riesgo en Contratación Pública mediante Open Data, Análisis de Redes, NLP y Modelos Locales

Propuesta Técnica de Trabajo Fin de Máster

Máster Universitario en Análisis y Visualización de Datos Masivos / Visual Analytics and Big Data — UNIR

Elaborado por: Marlon Cárdenas Bonett

Equipo de trabajo: Sebastián Alfonso Correa & Satoria Maria Hurtado Álvarez

Resumen del proyecto

ProcureWatch Analytics es una plataforma analítica multiagente que, a partir de datos abiertos de contratación pública española y europea, detecta **patrones anómalos, señales de riesgo y red flags en procesos de adjudicación, licitación y pago público**, con especial atención a comportamientos recurrentes en empresas adjudicatarias que podrían merecer revisión por parte de organismos de control o auditoría.

El sistema no emite juicios jurídicos ni declara fraude. Su función es construir una base analítica integrada que permita identificar: concentración inusual de adjudicaciones en un mismo proveedor o grupo de proveedores, patrones temporales atípicos en la publicación o resolución de licitaciones, discrepancias entre importes estimados y adjudicados, procedimientos de contratación utilizados de forma sistemáticamente diferenciada, y conexiones societarias o de red entre empresas adjudicatarias que presentan comportamientos de riesgo.

El núcleo académico del proyecto está en el **análisis de datos masivos**: integración de fuentes heterogéneas, construcción de indicadores analíticos, análisis de redes, detección de anomalías y visualización explicable. Los modelos de lenguaje locales, el OCR y los agentes cumplen un papel instrumental en la extracción, normalización y explicación. Este equilibrio hace del proyecto un TFM sólido, original y perfectamente defendible para el Máster en Análisis y Visualización de Datos Masivos.^[1]

1. Introducción

1.1 Motivación

La contratación pública representa en España aproximadamente el **12-15% del PIB** y constituye uno de los mecanismos de gasto público más relevantes para cualquier administración, desde municipios pequeños hasta el Estado central. Esa magnitud convierte la contratación pública en un ámbito especialmente expuesto a riesgos de irregularidad, y también en una fuente extraordinariamente rica para el análisis de datos masivos, dado que la legislación española obliga desde 2007 a publicar los contratos en formatos abiertos y reutilizables.^[2]

Propuesta Técnica TFM UNIR – Sopra Steria

En España, la Plataforma de Contratación del Sector Público (PLACE) centraliza la publicación de licitaciones, adjudicaciones y contratos de miles de organismos. La Agencia Tributaria ha protagonizado operaciones de desarticulación de tramas de fraude en contratación pública, como la de Cantabria en 2023, donde se detectaron adjudicaciones sistemáticamente dirigidas a empresas vinculadas a un funcionario responsable de los informes técnicos de valoración. La AEAT ha señalado explícitamente el cruce entre datos tributarios y datos de contratación como una de las líneas más prometedoras para la detección de irregularidades.^[3]

A pesar de esa disponibilidad de datos, los análisis sistemáticos, automatizados y open-source sobre contratación pública en España siguen siendo escasos. El reciente dataset longitudinal del BOE (2014-2024), publicado en 2026 con aproximadamente 97.000 contratos estructurados según el estándar OCDS, abre una oportunidad concreta para construir análisis reproducibles y de calidad sobre este dominio. Además, la literatura internacional ha demostrado de forma consistente que los métodos de machine learning y análisis de redes mejoran significativamente la detección de irregularidades en contratación pública respecto a los enfoques puramente basados en reglas.^{[4][5][6][7]}

ProcureWatch Analytics propone aprovechar esas oportunidades para construir un prototipo analítico funcional, local y reproducible que combine indicadores de red flags establecidos en la literatura con análisis de grafos de relaciones entre empresas y administraciones, NLP sobre documentos públicos y visualización analítica explicable.

Preguntas guía para la memoria:

- ¿Cuál es el volumen de contratos publicados en PLACE por año en España y cuántos organismos participan?
- ¿Qué tipos de irregularidades en contratación pública se han documentado en España en los últimos diez años?
- ¿Qué limitaciones tienen los sistemas actuales de auditoría y control de la contratación pública?
- ¿Qué evidencias existen en la literatura sobre la eficacia del análisis de datos para detectar patrones de riesgo en contratación pública?

1.2 Planteamiento del trabajo

Este TFM propone el diseño, desarrollo y evaluación de **ProcureWatch Analytics**, un prototipo que integra: (a) un pipeline de adquisición, limpieza e integración de datos Open Data de contratación pública española y europea en un estándar OCDS común; (b) un motor analítico de detección de red flags y patrones de riesgo basado en indicadores de la literatura y modelos estadísticos y de machine learning; (c) un módulo de análisis de redes societarias y de adjudicación para detectar concentraciones, relaciones sospechosas y patrones de

Propuesta Técnica TFM UNIR – Sopra Steria

comportamiento grupal; (d) un sistema OCR y de NLP para procesamiento de pliegos, resoluciones y documentos públicos; y (e) un front-end analítico con red de relaciones interactiva, panel de riesgo, evolución temporal y ficha explicativa de caso.

El sistema se validará sobre el dataset longitudinal del BOE (2014-2024) y los datos de PLACE, mediante escenarios de análisis definidos y métricas de evaluación cuantitativas.^{[5][4]}

Nota esencial para el equipo: Esta propuesta marca una dirección, no un enunciado cerrado. La empresa no os entrega una solución predefinida. Sois vosotros, como analistas de datos en formación, quienes debéis decidir el **alcance concreto**: qué tipo de contratos analizaréis, qué red flags priorizaréis, sobre qué corpus de datos trabajaréis y cómo evaluaréis el sistema. El primer borrador del TFM es el mecanismo para validar ese alcance. Llegad a la reunión de seguimiento con decisiones tomadas y argumentadas.

1.3 Estructura del trabajo

La memoria seguirá la plantilla oficial de UNIR:^[8]

1. Introducción y motivación
2. Contexto y estado del arte
3. Objetivos concretos y metodología de trabajo
4. Marco normativo
5. Desarrollo específico de la contribución (pipeline de datos, motor de red flags, análisis de redes, NLP, front-end)
6. Código fuente y datos analizados
7. Conclusiones
8. Limitaciones y trabajo futuro

2. Contexto y Estado del Arte

2.1 Contexto del problema: qué son los red flags en contratación pública

Antes de construir ningún sistema, el equipo necesita comprender con precisión qué es un **red flag en contratación pública**. Un red flag no equivale a fraude confirmado: es una señal estadísticamente asociada a mayor probabilidad de irregularidad en un proceso de contratación, que justifica una inspección más detallada por parte de un organismo de control.

La Open Contracting Partnership (OCP) y el proyecto europeo DIGIWHIST han documentado más de 150 indicadores de comportamiento sospechoso a lo largo de todas las fases del ciclo de contratación. Comprender

esos indicadores es obligatorio para el equipo, porque definen qué variables del dataset son analíticamente relevantes.^{[9][10]}

Los principales tipos de red flags que el equipo puede considerar son:

Red flags de licitación única o restringida: Un contrato recibe una sola oferta cuando el procedimiento es abierto, o se utiliza sistemáticamente un procedimiento negociado sin publicidad en contratos que superan umbrales razonables. Estos son dos de los indicadores con mayor soporte empírico en la literatura.^{[10][11][9]}

Red flags de concentración de adjudicatarios: Un mismo proveedor acumula de forma recurrente un porcentaje elevado de contratos adjudicados por un mismo organismo o en un mismo sector, especialmente cuando la concentración aumenta en el tiempo.

Red flags de desviación de importe: La diferencia entre el importe estimado de licitación y el importe real adjudicado es sistemáticamente alta en contratos de un mismo organismo o proveedor, lo que puede indicar estimaciones deliberadamente infladas o reducidas para condicionar la concurrencia.

Red flags temporales: Un contrato se publica y adjudica en plazos muy cortos, se publica fuera del horario administrativo habitual, se adjudica en periodos de menor visibilidad (festivos, cierres de ejercicio), o sigue patrones de agrupación temporal inusuales.

Red flags de procedimiento: Se utiliza el procedimiento de contratación menor —que no exige publicidad ni concurrencia— de forma recurrente con el mismo proveedor o en cantidades próximas al umbral que requeriría licitación pública.

Red flags de red societaria: Las empresas adjudicatarias comparten administradores, domicilios, teléfonos de contacto o estructura accionarial, lo que puede indicar comportamiento coordinado en las ofertas (colusión) o la existencia de grupos empresariales que se presentan formalmente como competidores.

Red flags combinados: La literatura más reciente demuestra que los modelos de machine learning que combinan múltiples red flags con características de red mejoran significativamente respecto a los enfoques de indicador único.^{[6][7]}

Preguntas guía para los estudiantes en este apartado:

- ¿Cuál es la distribución real de procedimientos de contratación en PLACE (abierto, negociado, menor)?
- ¿Cuántos contratos menores se adjudican anualmente al mismo proveedor en los organismos del dataset?
- ¿Qué porcentaje de contratos reciben una sola oferta según los datos disponibles?
- ¿Qué casos de irregularidades documentadas en España presentan qué combinación de red flags?

2.2 Estado del arte

Los estudiantes deben revisar y sintetizar los siguientes bloques temáticos, con un mínimo de cinco referencias académicas o técnicas de calidad por bloque:

Bloque A — Open Data de contratación pública y estándar OCDS:

- La Plataforma de Contratación del Sector Público (PLACE) en España: estructura, formatos, volumen y limitaciones de los datos publicados^{[12][13]}
- El estándar OCDS (Open Contracting Data Standard): campos, fases del ciclo contractual, alineación con datos españoles^{[14][10]}
- Dataset longitudinal BOE 2014-2024: metodología de extracción, 97.000 contratos, variables disponibles^{[4][5]}
- OpenTender.eu: datos de 35 países europeos con indicadores OCDS, cobertura temporal 2007-2024^{[15][16]}
- Comparativa internacional de portales de contratación abierta: calidad, completitud y comparabilidad entre sistemas nacionales

Bloque B — Red flags, indicadores de riesgo y corrupción en contratación:

- Taxonomía de red flags en contratación pública: categorías, fases del ciclo y evidencia empírica^{[9][10]}
- Corruption Red Flags in Public Procurement: evidencia desde Italia con random forest^[11]
- Positive-Unlabeled Learning para detección de corrupción en contratación: enfoque con etiquetas incompletas^[6]
- Hybrid Machine Learning Framework para corrupción en contratación: logistic regression + random forest + clustering^[7]
- Anomaly Detection in Public Procurement using OCDS: detección de anomalías sobre contratos paraguayos^[14]
- Índices compuestos de riesgo: CRI (Corruption Risk Index) del proyecto DIGIWHIST^{[17][16]}

Bloque C — Análisis de redes en detección de irregularidades:

- Análisis de redes bipartitas empresa-organismo contratante: métricas de centralidad y concentración
- Network-derived features en modelos de detección de corrupción: eigenvector centrality, core-periphery^[6]
- Grafos de relaciones societarias: uso de datos de registro mercantil y licitadores para construir redes de propiedad

Propuesta Técnica TFM UNIR – Sopra Steria

- Community detection en grafos de contratación: algoritmos de Louvain, Leiden y sus aplicaciones en fraude
- Knowledge graphs para análisis de relaciones en contratación pública: Neo4j, RDF, SPARQL

Bloque D — NLP y procesamiento de documentos de contratación:

- Extracción de información estructurada de pliegos y resoluciones: Named Entity Recognition, relaciones entre entidades
- Clasificación automática de documentos de contratación: categorías CPV, tipos de contrato, sectores
- LLMs locales para análisis de documentos jurídico-administrativos: Qwen3, Mistral, Phi-4-mini
- OCR aplicado a documentos de contratación: Docling, Surya — comparativa en documentos administrativos
- NLP para detección de señales de riesgo en texto libre: análisis de pliegos, memorias justificativas y resoluciones

Bloque E — Visualización analítica y explicabilidad en sistemas de riesgo:

- Visualización de grafos de red en sistemas de detección de fraude: Cytoscape.js, Sigma.js, NetworkX
- Dashboards de riesgo para organismos de control: principios de diseño, jerarquía de información, flujo de revisión
- Explicabilidad en modelos de scoring de contratación: SHAP values, LIME, factores de riesgo por caso
- Herramientas open-source de visualización de grafos y datos tabulares: combinación de Streamlit + Plotly + Sigma/Pyvis
- Casos de uso de plataformas de análisis de contratación pública: OpenTender, Gobierno Contratación, ¿Quién cobra del Estado?

2.3 Conclusiones del estado del arte

Este apartado debe sintetizar qué brechas justifican el desarrollo de ProcureWatch Analytics:

- Existen datos abiertos de alta calidad sobre contratación pública española (BOE, PLACE), pero no hay herramientas open-source que los integren y analicen de forma sistemática con un enfoque de red flags y análisis de redes.
- La literatura demuestra que los modelos que combinan indicadores de red flags con análisis de redes mejoran significativamente la detección de patrones de riesgo, pero esos modelos rara vez se implementan sobre datos españoles y con herramientas locales reproducibles.^[6]

- No existe un prototipo open-source, local y evaluable que combine pipeline OCDS, análisis de redes, NLP documental y visualización explicable sobre contratación pública española.
- Los datos del BOE 2014-2024 y de PLACE ofrecen una oportunidad concreta para construir ese prototipo con evidencia real y un horizonte temporal suficiente para análisis de tendencias.^{[5][4]}

3. Objetivos concretos y metodología de trabajo

3.1 Objetivo general

Diseñar, desarrollar y evaluar **ProcureWatch Analytics**, un prototipo de plataforma analítica multiagente que, a partir de datos Open Data de contratación pública española y europea, detecte, cuantifique y visualice patrones de riesgo e indicadores de red flags en licitaciones, adjudicaciones y empresas adjudicatarias, mediante análisis de datos masivos, análisis de redes societarias, NLP documental y modelos de scoring de anomalías, generando fichas de riesgo explicables que apoyen la priorización de casos para revisión por organismos de control.

3.2 Objetivos específicos

- **OE1 — Análisis del dominio y las fuentes:** Estudiar el ciclo de contratación pública española, la estructura y calidad de los datos disponibles en PLACE y en el dataset BOE 2014-2024, identificando las variables más relevantes para la detección de red flags.
- **OE2 — Diseño del modelo de datos analítico:** Definir el esquema de datos integrado y armonizado con el estándar OCDS que unificará información de contratos, licitaciones, adjudicatarios, órganos de contratación y relaciones societarias.
- **OE3 — Construcción del pipeline de datos:** Implementar un pipeline reproducible de descarga, limpieza, normalización, enriquecimiento y carga de datos Open Data de contratación pública en la base de datos analítica.
- **OE4 — Desarrollo del motor de red flags:** Diseñar e implementar un conjunto de indicadores analíticos de red flags basados en la literatura y en el estándar OCDS, complementados con modelos estadísticos y de machine learning para scoring de riesgo por contrato y por adjudicatario.
- **OE5 — Módulo de análisis de redes:** Construir y analizar el grafo de relaciones entre empresas adjudicatarias, órganos de contratación y contratos, detectando comunidades, patrones de concentración, centralidades atípicas y posibles conexiones societarias relevantes.
- **OE6 — Módulo NLP y documental:** Implementar un sistema de extracción de información estructurada sobre pliegos, resoluciones y memorias justificativas públicas, indexarlos en un corpus recuperable y enriquecer las fichas de riesgo con contexto documental relevante.

- **OE7 — Desarrollo del front-end analítico:** Construir una interfaz con grafo de relaciones interactivo, panel de riesgo, evolución temporal de indicadores y ficha explicativa de caso, que permita explorar, filtrar y revisar patrones de riesgo de forma visual y argumentada.
- **OE8 — Evaluación del sistema:** Validar el prototipo mediante métricas de calidad del pipeline, calidad del scoring de red flags, calidad del módulo RAG documental y usabilidad de la interfaz.

3.3 Metodología del trabajo

El proyecto sigue una metodología iterativa adaptada de **CRISP-DM** para la componente analítica, combinada con un desarrollo incremental por módulos para el prototipo:

Fase 0 — Formación y configuración (Semanas 1-2): Completar los recursos formativos recomendados y configurar el entorno local: Python, Docker, Ollama, PostgreSQL, Neo4j Community, Qdrant, GitHub Copilot.

Fase 1 — Comprensión del dominio y los datos (Semanas 3-4): Análisis exploratorio profundo del dataset BOE 2014-2024 y muestra de PLACE. Estadística descriptiva, perfilado de calidad, identificación de variables clave para red flags. Elaboración del modelo de datos OCDS adaptado.

Fase 2 — Preparación de datos e infraestructura (Semanas 5-6): Pipeline de descarga, limpieza, normalización, armonización OCDS y carga en PostgreSQL. Generación de la red bipartita empresa-organismo en Neo4j.

Fase 3 — Motor de red flags (Semanas 7-9): Implementación de indicadores analíticos, scoring compuesto por contrato y por adjudicatario. Comparativa de enfoques: reglas explícitas, Isolation Forest, modelos supervisados con etiquetas parciales.

Fase 4 — Análisis de redes y NLP (Semanas 10-12): Análisis del grafo (centralidad, comunidades, concentración). OCR de pliegos y resoluciones con Docling. Indexación en Qdrant. Motor RAG híbrido para recuperación documental por caso.

Fase 5 — Sistema multiagente y front-end (Semanas 13-14): Integración del sistema de agentes con LangGraph. Implementación del front-end con Streamlit, Pyvis/Sigma.js y Plotly.

Fase 6 — Evaluación (Semanas 15-16): Evaluación con métricas definidas, análisis de casos, refinamiento.

Fase 7 — Documentación y cierre (Semanas 17-18): Memoria, repositorio GitHub, presentación.

4. Marco Normativo

Los estudiantes deben revisar y describir las implicaciones de las siguientes normativas en el diseño del sistema:^[8]

Ley 9/2017 de Contratos del Sector Público (LCSP): Marco regulatorio fundamental de la contratación pública en España. Regula tipos de contratos, procedimientos de adjudicación, publicidad obligatoria, umbrales y obligaciones de transparencia. El equipo debe conocer bien qué datos obliga a publicar y en qué formatos, porque eso determina la calidad y completitud de las fuentes de datos.^[13]

RGPD (Reglamento UE 2016/679) y LOPDGDD (Ley Orgánica 3/2018): Los datos de contratación incluyen información sobre personas físicas (administradores de empresas, representantes). El sistema debe garantizar que el análisis se realiza sobre datos publicados en el marco de obligaciones de transparencia y no sobre datos personales adicionales, y que no se construyen perfiles que excedan la finalidad legítima del análisis de contratación pública.

Reglamento de IA de la UE (AI Act, 2024): Los sistemas que generan puntuaciones de riesgo que podrían influir en decisiones de organismos de control sobre empresas o contratos pueden clasificarse como **sistemas de alto riesgo**. El prototipo debe diseñarse con trazabilidad completa, supervisión humana obligatoria y sin capacidad de emitir decisiones automáticas.

Ley 19/2013 de transparencia, acceso a la información y buen gobierno: Marco de reutilización de información pública española. Define qué información es de acceso libre, cuáles son sus condiciones de reutilización y qué restricciones aplican.

Directiva UE 2019/1024 sobre datos abiertos y reutilización de la información del sector público: Refuerza la obligación de publicar datos públicos en formatos abiertos y reutilizables. Relevante para entender los derechos y limitaciones del equipo al construir análisis sobre datos de contratación.


Ley Orgánica 4/2015 de Seguridad Ciudadana y normativa antilavado de capitales: Si el análisis incorpora datos de registro mercantil o información societaria abierta, hay que revisar qué restricciones aplican sobre el uso de información de titularidad real.

Directiva 2022/2557 de Resiliencia de Entidades Críticas (CER): Contextualiza la necesidad de mecanismos de control en contratación relacionada con infraestructuras críticas.

Uso ético de modelos preentrenados: El LLM local tiene un papel estrictamente auxiliar: estructurar documentos, extraer entidades y generar explicaciones de casos. No puede ser el elemento que decida si un contrato es sospechoso. La decisión siempre es humana.

5. Arquitectura técnica y desarrollo

5.1 Arquitectura general del sistema



5.2 Stack tecnológico completo

Capa	Tecnología	Justificación
Pipeline de datos	Python + Pandas + DuckDB	Estándar para transformación ETL y análisis OLAP sobre datos tabulares; DuckDB permite consultas SQL rápidas sobre Parquet sin servidor
Base de datos relacional	PostgreSQL	Almacenamiento de contratos normalizados en esquema OCDS; consultas analíticas complejas sobre adjudicatarios, organismos e importes
Base de datos de grafos	Neo4j Community	Almacenamiento y consulta del grafo empresa-organismo-contrato; análisis de comunidades, centralidad y caminos entre entidades
OCR documental	Docling (IBM, MIT)	Mejor opción open-source para PDFs administrativos complejos con tablas y layouts estructurados; exporta JSON y Markdown
OCR alternativo	Surya	Documentos con múltiples columnas o layouts densos; útil como comparativa
Embeddings locales	BGE-M3 (vía Ollama)	Modelo multilingüe SOTA para recuperación densa; funciona sin API key en local

Vector store	Qdrant (Docker local)	Open-source, búsqueda híbrida, filtros de metadatos; indexación del corpus documental de pliegos y resoluciones
LLM local principal	Qwen3 7B (vía Ollama)	Apache 2.0; excelente en generación JSON estructurada; corre en CPU con 16 GB RAM
LLM alternativo	Mistral Small 3	Apache 2.0; referencia comparativa para tareas de síntesis y clasificación de documentos
Orquestación agentes	LangGraph	Grafo de estados para flujos multiagente con bucles de corrección y estado compartido
Framework RAG	LangChain	Integración nativa con LangGraph, Qdrant y Ollama
Análisis de grafos	NetworkX + PyVis	Cálculo de métricas de red (centralidad, clustering, comunidades) y generación de visualizaciones interactivas
Análisis de comunidades	python-louvain / leidenalg	Detección de comunidades en el grafo de contratación
Detección anomalías	scikit-learn	Isolation Forest, LOF, DBSCAN — detección de contratos o adjudicatarios atípicos
NLP y NER	spaCy (modelo es_core_news_lg)	Extracción de entidades en documentos de contratación en español
Evaluación RAG	RAGAS	Framework estándar para evaluar calidad de recuperación y generación
Front-end	Streamlit + Plotly + Pyvis	Rápido de implementar, open-source; Pyvis para visualización del grafo interactivo
API Backend	FastAPI (Python)	Alto rendimiento, async, documentación automática OpenAPI
Contenerización	Docker + Docker Compose	Despliegue reproducible (PostgreSQL, Neo4j, Qdrant, Ollama, backend, frontend)
Diseño UI / prototipado	Google Stitch	Prototipado de interfaces de alta fidelidad con IA; el estudiante elige y ajusta
Asistencia programación	GitHub Copilot	Autocompletado y generación de tests; nunca para diseño técnico ni análisis

5.3 Descripción de agentes especializados

Dado que el equipo es de dos personas, la distribución de agentes debe ser especialmente clara. Cada estudiante debe liderar el desarrollo de módulos suficientemente diferenciados como para que, individualmente, pudieran constituir un TFM propio.^[1]

Agente 1 — Pipeline de Datos y Normalización OCDS (Sebastián Alfonso Correa):

Autor: Marlon Cárdenas Bonett - 2026

Propuesta Técnica TFM UNIR – Sopra Steria

- Coordina la descarga, limpieza, normalización y carga de datos de contratación pública según el esquema OCDS.
- Detecta y resuelve inconsistencias en los datos: importes negativos, fechas incoherentes, referencias duplicadas, NIF mal formateados.
- Gestiona la actualización incremental de la base de datos y la trazabilidad de las fuentes.
- Construye y mantiene el grafo empresa-organismo-contrato en Neo4j.
- Herramientas disponibles: `download_place_data`, `normalize_to_ocds`, `validate_nif_entities`, `load_to_postgres`, `build_contract_graph`, `profile_data_quality`

Agente 2 — Red Flags y Scoring (Sebastián Alfonso Correa):

- Calcula el score de riesgo por contrato y por adjudicatario combinando indicadores de red flags de la literatura OCDS con métricas de red y modelos estadísticos.
- Prioriza casos según nivel de riesgo y genera el ranking analítico para el panel de revisión.
- Implementa y compara enfoques: reglas OCDS explícitas, Isolation Forest, Positive-Unlabeled Learning para datasets sin etiquetas negativas claras.
- Herramientas: `calculate_single_bid_flag`, `detect_procedure_anomaly`, `compute_amount_deviation`, `score_temporal_pattern`, `rank_risk_entities`, `compute_concentration_index`

Agente 3 — Análisis de Redes y Comunidades (Saturia Maria Hurtado Álvarez):

- Analiza el grafo de relaciones empresa-organismo-contrato: centralidad, clustering, comunidades sospechosas, caminos entre entidades.
- Detecta patrones de concentración atípica: adjudicatarios con alta centralidad en nichos de un solo organismo, comunidades densamente conectadas con bajo número de proveedores.
- Integra datos de registro mercantil o licitadores cuando estén disponibles para enriquecer el grafo con relaciones societarias.
- Herramientas: `compute centrality_metrics`, `detect_communities_louvain`, `find_suspicious_clusters`, `identify_sole_supplier_patterns`, `build_ownership_subgraph`

Agente 4 — NLP, OCR y Recuperación Documental (Saturia Maria Hurtado Álvarez):

- Procesa pliegos, resoluciones y memorias justificativas públicas con Docling y spaCy para extraer entidades (organismos, importes, plazos, criterios de adjudicación, proveedores mencionados).
- Mantiene un corpus documental indexado en Qdrant para recuperación de contexto relevante por caso.

Propuesta Técnica TFM UNIR – Sopra Steria

- Genera la ficha explicativa de cada caso de riesgo con el LLM local, usando el contexto documental recuperado y los indicadores calculados.
- Herramientas: `extract_pliego_entities`, `index_document_corpus`, `search_relevant_context`, `generate_case_explanation`, `retrieve_normative_fragments`

5.4 Modelo de datos analítico

El esquema OCDS adaptado que debe unificar los datos del sistema incluirá como mínimo los siguientes campos:

```
CONTRATO {
  id_contrato,
  id_licitacion,
  organismo_contratante,
  codigo_organismo,
  nivel_administracion (central | autonómica | local),
  tipo_contrato (obras | servicios | suministros | concesión),
  procedimiento (abierto | restringido | negociado | menor | emergencia),
  cpv_codigo,
  cpv_descripcion,
  importe_estimado,
  importe_adjudicado,
  ratio_desviacion_importe,
  fecha_publicacion,
  fecha_adjudicacion,
  dias_resolucion,
  numero_ofertas_recibidas,
  id_adjudicatario,
  nif_adjudicatario,
  nombre_adjudicatario,
  score_red_flags_total (0-100),
  red_flags_activados (lista),
  nivel_riesgo (bajo | medio | alto | crítico),
  score_centralidad_red,
  comunidad_red,
  fragmentos_documentales_recuperados (lista),
  fuentes_cruzadas (lista),
  estado_revision (pendiente | en_revision | cerrado)
}
```

```
ADJUDICATARIO {
  nif,
  nombre,
  forma_juridica,
  sector_actividad,
```

```

total_contratos,
total_importe_adjudicado,
organismos_distintos,
procedimientos_menores_ratio,
tasa_adjudicacion_licitacion,
score_riesgo_agregado,
nivel_centralidad_red,
comunidades_participacion (lista),
red_flags_recurrentes (lista)
}

```

5.5 Indicadores de red flags implementables

El equipo debe implementar al menos los siguientes indicadores, tomados de la literatura OCDS y adaptados al dataset español:^{[10][11][9]}

```

def flag_single_bid(contract):
    """RF-01: Licitación con una sola oferta en procedimiento abierto."""
    return contract['num_ofertas'] == 1 and contract['procedimiento'] == 'abierto'

def flag_procedure_anomaly(contract, threshold_negotiated=0.30):
    """RF-02: Ratio de procedimientos negociados por encima del umbral para ese organismo."""
    return contract['ratio_negociados_organismo'] > threshold_negotiated

def flag_amount_deviation(contract, threshold=0.20):
    """RF-03: Desviación entre importe estimado y adjudicado superior al umbral."""
    if contract['importe_estimado'] == 0:
        return False
    deviation = abs(contract['importe_adjudicado'] - contract['importe_estimado'])
    return deviation / contract['importe_estimado'] > threshold

def flag_short_resolution(contract, min_days=5):
    """RF-04: Plazo de resolución inusualmente corto."""
    return contract['dias_resolucion'] < min_days

def flag_concentration(adjudicatario, threshold=0.60):
    """RF-05: Un adjudicatario concentra más del umbral de contratos de un organismo."""
    return adjudicatario['ratio_contratos_organismo_max'] > threshold

def flag_repeated_minor_contracts(adjudicatario, threshold=0.50):
    """RF-06: Más del umbral de contratos son menores con el mismo organismo."""
    return adjudicatario['ratio_menores_mismo_organismo'] > threshold

```

Propuesta Técnica TFM UNIR – Sopra Steria

```
def compute_composite_score(contract, adjudicatario, network_metrics):
    """Calcula el score compuesto ponderando red flags e indicadores de red."""
    flags = [
        flag_single_bid(contract),
        flag_procedure_anomaly(contract),
        flag_amount_deviation(contract),
        flag_short_resolution(contract),
        flag_concentration(adjudicatario),
        flag_repeated_minor_contracts(adjudicatario)
    ]
    base_score = sum(flags) / len(flags) * 100
    network_bonus = network_metrics.get('centrality_score', 0) * 20
    return min(base_score + network_bonus, 100)
```

5.6 Ejemplo de implementación: análisis del grafo en Neo4j

```
from neo4j import GraphDatabase
import networkx as nx
from community import community_louvain

# Consulta Cypher: detectar adjudicatarios con alta concentración en un organismo
cypher_concentration = """
MATCH (e:Empresa)-[r:ADJUDICADO]->(c:Contrato)-[:CONTRATADO_POR]->(o:Organismo)
WITH e, o, count(c) as num_contratos, sum(r.importe) as total_importe
WHERE num_contratos > 5
WITH o, e, num_contratos, total_importe,
     sum(num_contratos) OVER (PARTITION BY o) as total_organismo
RETURN e.nombre, o.nombre, num_contratos,
       round(100.0 * num_contratos / total_organismo, 2) as pct_contratos
ORDER BY pct_contratos DESC
LIMIT 50
"""

# Detección de comunidades con python-louvain sobre grafo NetworkX
G = nx.Graph()
# ... (carga de datos desde PostgreSQL)
partition = community_louvain.best_partition(G)
modularity = community_louvain.modularity(partition, G)
print(f"Modularity: {modularity:.3f} | Comunidades: {len(set(partition.values()))}")

# Centralidad de intermediación: identifica entidades "puente" en la red
betweenness = nx.betweenness_centrality(G, normalized=True)
```

```
top_brokers = sorted(betweenness.items(), key=lambda x: x[1], reverse=True)[:20]
```

5.7 Ejemplo de implementación: pipeline RAG híbrido para documentos de contratación

```
from qdrant_client import QdrantClient
from langchain_community.vectorstores import Qdrant
from langchain_community.embeddings import OllamaEmbeddings
from langchain_community.retrievers import BM25Retriever
from langchain.retrievers import EnsembleRetriever

# Recuperador semántico (denso) sobre corpus de pliegos y resoluciones
dense_retriever = Qdrant(
    client=QdrantClient("localhost", port=6333),
    collection_name="procurewatch_docs",
    embeddings=OllamaEmbeddings(model="bge-m3")
).as_retriever(search_kwargs={"k": 8})

# Recuperador léxico (BM25) para términos técnicos específicos de contratación
sparse_retriever = BM25Retriever.from_documents(documents, k=8)

# Fusión híbrida con Reciprocal Rank Fusion
hybrid_retriever = EnsembleRetriever(
    retrievers=[dense_retriever, sparse_retriever],
    weights=[0.60, 0.40]
)

# Recuperar contexto documental para explicar un caso de riesgo concreto
query = "procedimiento negociado sin publicidad contrato menor fraccionamiento NIF B12345678"
context_docs = hybrid_retriever.invoke(query)
```

6. Fuentes de datos Open Data

Dataset	URL	Contenido	Formato	Periodo
PLACE — Licitaciones España	https://www.hacienda.gob.es/es-ES/GobiernoAbierto/DatosAbiertos/Paginas/licitaciones_plataforma_contratacion.aspx	Contratos, adjudicaciones, órganos de contratación	XLSX, JSON, XML	2018- 2026
BOE Dataset 2014-2024	https://arxiv.org/abs/2602.16731	~97.000 contratos estructurados según OCDS	CSV, JSON	2014- 2024

Propuesta Técnica TFM UNIR – Sopra Steria

OpenTender.eu — España	https://opentender.eu/es/download	Contratos españoles en formato OCDS con indicadores de riesgo precalculados	JSON, CSV	2007- 2024
OpenTender — EU Institutions	https://data.open-contracting.org/en/publication/94	Datos de 35 países europeos en formato OCDS	JSON	2007- 2024
Datos Abiertos Ministerio Hacienda	https://datos.gob.es/en/catalogo/conjuntos-datos	Catálogo de contratos y licitaciones por organismo	Múltiples	Continuo
OpenData Euskadi — Contratación	https://www.euskadi.eus/gobierno-vasco/-/2024/nueva-api-rest-sobre-la-plataforma-kontratazioa/	Licitaciones y contratos del sector público vasco vía API REST	JSON, XLSX	2020- 2026
Registro de Licitadores ROLECE	https://www.hacienda.gob.es/es-ES/AreasTematicas/Contratacion/ROLECE/Paginas/ROLECE.aspx	Empresas clasificadas para contratar con el Estado	Consulta web	Continuo
OpenData Registradores	https://opendata.registradores.org/en/	Datos registrales agregados por empresa y municipio	CSV, XLSX	Periódico
Datos Abiertos AEAT	https://sede.agenciatributaria.gob.es/Sede/en_gb/gobierno-abierto/reutilizacion-informacion/datos-disponibles-catalogo-datos-abiertos.html	Estadísticas tributarias agregadas por sector y territorio	CSV, XLSX	Anual
TED — Tenders Electronic Daily (UE)	https://ted.europa.eu/en/advanced-search	Contratos públicos de la UE por encima de umbrales comunitarios	XML, CSV	1994- 2026

Propuesta Técnica TFM UNIR – Sopra Steria

Transparencia Internacional — CPI	https://www.transparency.org/en/cpi	Índice de Percepción de Corrupción por país	CSV	Anual
OCDS Red Flags Reference	https://www.open-contracting.org/wp-content/uploads/2016/11/OCF2016-Red-flags-for-integrityshared-1.pdf	Catálogo de 150+ red flags en formato OCDS	PDF	Referencia

Nota para el equipo: El punto de partida más sólido es el **dataset BOE 2014-2024** (ya estructurado en OCDS) y los datos de **OpenTender.eu** (que incluyen indicadores de riesgo precalculados para España). Con esas dos fuentes ya hay suficiente base para un TFM de calidad. Las demás fuentes son complementos opcionales para enriquecer el análisis o comparar resultados.

7. Repositorios GitHub de referencia

Los estudiantes deben estudiar y citar los siguientes repositorios en el estado del arte y el desarrollo:

Repositorio	URL	Relevancia
LangGraph (oficial)	https://github.com/langchain-ai/langgraph	Orquestación multiagente con grafo de estados
Agentic RAG con LangGraph	https://github.com/damerlaroja/langgraph-agentic-rag	RAG con auto-corrección y máquina de estados
Corrective RAG local + Qwen	https://github.com/jacoblee93/corrective-local-rag-qwen	RAG correctivo con Qwen vía Ollama
NetworkX (análisis de grafos)	https://github.com/networkx/networkx	Biblioteca estándar de análisis de redes en Python
Neo4j Python Driver	https://github.com/neo4j/neo4j-python-driver	Conexión a Neo4j desde Python para análisis de grafos
python-louvain	https://github.com/taynaud/python-louvain	Detección de comunidades en grafos con algoritmo Louvain
PyVis (visualización de grafos)	https://github.com/WestHealth/pyvis	Grafos interactivos en Python para Streamlit y web
spaCy es_core_news_lg	https://github.com/explosion/spaCy	NLP en español: NER, POS tagging, análisis de dependencias
Docling (IBM OCR)	https://github.com/DS4SD/docling	OCR estructurado de PDFs complejos

RAGAS (evaluación RAG)	https://github.com/explodinggradients/ragas	Evaluación de calidad de sistemas RAG
Multi-Agent Data Analysis	https://github.com/aws-samples/langgraph-multi-agent	Multiagente para análisis de datos con LangGraph
OpenTender análisis	https://opentender.eu/es	Plataforma de referencia con indicadores de riesgo precalculados

8. Cursos y recursos de formación recomendados

Bloque 0 — Fundamentos (Semanas 1-2)

#	Curso	Plataforma	URL	Duración
1	AI Python for Beginners	DeepLearning.AI	https://www.deeplearning.ai/short-courses/ai-python-for-beginners/	4h
2	Generative AI for Everyone	DeepLearning.AI	https://www.deeplearning.ai/courses/generative-ai-for-everyone/	5h

Bloque 1 — Análisis de datos y grafos (Semanas 2-3)

#	Recurso	URL	Descripción
3	NetworkX Tutorial	https://networkx.org/documentation/stable/tutorial.html	Análisis de grafos con Python
4	Neo4j Graph Data Science	https://neo4j.com/developer/graph-data-science/	Algoritmos de grafos en Neo4j
5	Introduction to Graph Analytics	https://www.datacamp.com/courses/introduction-to-network-analysis-in-python	Análisis de redes con Python

Bloque 2 — LLMs locales y LangChain (Semanas 3-4)

#	Curso	URL	Duración
6	LangChain for LLM Application Development	https://www.deeplearning.ai/short-courses/langchain-for-llm-application-development/	3h
7	LangChain: Chat with Your Data	https://www.deeplearning.ai/short-courses/langchain-chat-with-your-data/	3h

Bloque 3 — Agentes y RAG (Semanas 4-5)

Propuesta Técnica TFM UNIR – Sopra Steria

#	Curso	URL	Duración
8	AI Agents in LangGraph	https://www.deeplearning.ai/short-courses/ai-agents-in-langgraph/	4h
9	Building Applications with Vector Databases	https://www.deeplearning.ai/short-courses/building-applications-vector-databases/	4h

Bloque 4 — Ollama, modelos locales y NLP (Semana 5)

#	Recurso	URL	Descripción
10	Ollama documentación oficial	https://ollama.com/	Instalación y uso de Qwen3, Mistral, BGE-M3
11	spaCy Course	https://course.spacy.io/en/	NLP en Python: NER, pipelines, modelos en español
12	Docling documentation	https://github.com/DS4SD/docling	OCR estructurado con IBM Docling

9. Plan de trabajo detallado (18 semanas)

Semana	Fase	Actividades	Entregable	Responsable
1-2	Formación	Cursos Bloques 0 y 1; setup entorno (Python, Docker, Ollama, PostgreSQL, Neo4j, Qdrant, GitHub Copilot)	Entorno configurado + Qwen3 funcionando localmente	Ambos
3	Formación + Análisis	Cursos Bloques 2 y 3; análisis exploratorio del dataset BOE y OpenTender; perfilado de calidad	Informe de exploración de datos v1 + selección de fuentes definitiva	Ambos
4	Diseño	Modelo de datos OCDS adaptado; esquema PostgreSQL y Neo4j; arquitectura de agentes; wireframes del front (Google Stitch)	Documento de arquitectura aprobado + wireframes	Ambos
5	Datos	Descarga y carga en PostgreSQL del dataset BOE; normalización OCDS; validación de NIF y campos clave	Base de datos de contratos poblada y documentada	Sebastián
6	Datos	Integración de OpenTender España; construcción del grafo bipartito empresa-organismo-contrato en Neo4j	Grafo de contratación construido y consultable	Sebastián
7	Red Flags	Implementación de indicadores RF-01 a RF-06 y cálculo de score compuesto por contrato	Módulo de red flags básico con primeros casos priorizados	Sebastián
8	Red Flags	Integración de Isolation Forest y Positive-Unlabeled Learning; ajuste de umbrales	Módulo de detección de anomalías con comparativa de enfoques	Sebastián

9	Red Flags	Evaluación cualitativa de casos priorizados; documentación del modelo de scoring	Informe de evaluación del motor de red flags v1	Sebastián
10	Grafos	Análisis de comunidades (Louvain); cálculo de centralidad; detección de patrones de concentración	Informe de análisis de red con comunidades y entidades atípicas identificadas	Saturia
11	NLP y OCR	Procesamiento de pliegos y resoluciones con Docling + spaCy; extracción de entidades	Corpus documental procesado e indexado en Qdrant	Saturia
12	Agente RAG	Implementación del retriever híbrido; tests de recuperación de contexto por caso; evaluación RAGAS	Motor RAG funcionando con métricas básicas documentadas	Saturia
13	Agente explicación	Implementación del agente de generación de fichas de caso; prompts controlados con Qwen3	Fichas de caso generables en JSON y texto estructurado	Ambos
14	Front-end	Mapa/grafó interactivo (Pyvis), panel de riesgo y timeline (Plotly), ficha de caso (Streamlit)	Interfaz funcional básica integrada con backend	Saturia
15	Integración	Conexión completa front-end / backend / agentes; tests end-to-end; corrección de bugs	Demo funcional integrada y demostrable	Ambos
16	Evaluación	Evaluación con escenarios definidos; análisis de resultados; refinamiento del scoring y visualización	Informe de evaluación final completo	Ambos
17-18	Documentación	Redacción de la memoria TFM; repositorio GitHub; documentación técnica; preparación de la defensa	Memoria final + repositorio + presentación	Ambos

10. Métricas de evaluación

Calidad del pipeline de datos:

- Completitud de campos OCDS críticos tras normalización: objetivo > 90%
- Tasa de NIF válidos y normalizados sobre el total de contratos: objetivo > 85%
- Coherencia temporal (fechas publicación < adjudicación): objetivo > 98%

Calidad del motor de red flags:

- Precisión sobre casos con ground truth parcial disponible (contratos de procedimiento menor que superan umbrales, licitaciones únicas verificables): objetivo > 70%

Propuesta Técnica TFM UNIR – Sopra Steria

- Estabilidad del score ante variaciones de umbral en $\pm 10\%$
- Comparativa de rendimiento entre reglas OCDS, Isolation Forest y Positive-Unlabeled Learning
- Ranking de red flags por frecuencia de activación y correlación con casos documentados

Calidad del análisis de redes:

- Modularidad del grafo con algoritmo Louvain: objetivo $Q > 0.30$ (red con estructura de comunidad real)
- Recall de entidades en comunidades conocidas (cuando exista información pública de casos)
- Correlación entre score de centralidad de intermediación y score de red flags

Calidad del sistema RAG documental (framework RAGAS):

- Faithfulness: objetivo > 0.80
- Answer Relevancy: objetivo > 0.75
- Context Recall: objetivo > 0.70

Calidad de la interfaz analítica:

- SUS (System Usability Scale): objetivo > 68 (nivel "acceptable")^[2]
- Tiempo medio para localizar, interpretar y documentar un caso de riesgo desde el panel: objetivo < 5 minutos
- Claridad y completitud de la ficha explicativa valorada por usuarios técnicos: escala Likert 1-5, objetivo > 3.5

11. Lo que se espera del equipo: el primer borrador como validación del alcance

Esta propuesta técnica es una **orientación sólida**, no un enunciado cerrado. Sois vosotros, Sebastián y Satoria, quienes debéis convertirla en una propuesta concreta y propia. La empresa no os dice qué contratos analizar, qué red flags priorizar ni cómo dividir el trabajo: vosotros debéis investigar, decidir y argumentar.

El **primer borrador del TFM** es el mecanismo de validación de vuestra propuesta. Debe incluir:

1. **Análisis del contexto:** explicad en qué consiste el problema de las irregularidades en contratación pública, con datos reales que justifiquen su relevancia en España.
2. **Estado del arte:** revisión de los cinco bloques temáticos con mínimo diez referencias en formato APA y una conclusión que justifique ProcureWatch Analytics como aportación nueva.
3. **Objetivos claros:** un objetivo general SMART y entre seis y ocho objetivos específicos con verbo en infinitivo, medibles y operativos.

4. **Metodología:** fases, organización del trabajo entre los dos integrantes y entregables previstos por fase.

Sobre el alcance, las preguntas que debéis poder responder antes de escribir ese borrador son: **¿qué tipo de contratos vais a analizar?, ¿qué red flags vais a priorizar?, ¿sobre qué fuentes de datos concretas trabajaréis? y ¿cómo demostraréis que el sistema tiene utilidad analítica?**

La organización os convocará a una sesión de revisión del borrador. Llegad con decisiones tomadas: cuanto más avancéis antes de esa sesión, más productivo será el feedback que recibiréis.

Referencias

Ministerio de Hacienda de España. (2024). *Plataforma de Contratación del Sector Público: datos abiertos de licitaciones*. https://www.hacienda.gob.es/es-ES/GobiernoAbierto/DatosAbiertos/Paginas/licitaciones_plataforma_contratacion.aspx^[2]

Muñoz Pla, M. (2026). *A decade of public procurement in Spain: A longitudinal open dataset from the BOE (2014-2024)*. arXiv. <https://arxiv.org/abs/2602.16731>^[18]

Agencia Tributaria de España. (2023). *Desarticulada una trama de fraude en la contratación de obra pública en Cantabria*. [https://sede.agenciatributaria.gob.es/Sede/Desarticulada una trama de fraude en la contratacion de obra publica en Cantabria.htm](https://sede.agenciatributaria.gob.es/Sede/Desarticulada_una_trama_de_fraude_en_la_contratacion_de_obra_publica_en_Cantabria.htm)^[19]

Universidad Internacional de La Rioja. (2024). *Plantilla de Trabajo Fin de Estudios Grupal*. UNIR.^[8]

Open Contracting Partnership. (2016). *Red flags for integrity: Giving the green light to open data solutions*. <https://www.open-contracting.org/wp-content/uploads/2016/11/OCP2016-Red-flags-for-integrityshared-1.pdf>^[20]

Regional Integrity and Civic Governance. (2023). *Guide to identify corruption risks in public procurement using data science*. <https://ricg.org/wp-content/uploads/2023/01/Guide-to-identify-corruptions-risks-in-public-procurement-using-data-science.pdf>^[21]

Fazekas, M., & Cingolani, L. (2025). *Opentender: Public procurement data for transparency and accountability*. Government Transparency Institute. <https://www.govtransparency.eu/opentender/>^[22]

Fazekas, M., & Horn, A. (2021). *Overview of procurement integrity and introduction to opentender.eu*. Government Transparency Institute. <https://www.govtransparency.eu>^[23]

Wachs, J., Fazekas, M., & Kertész, J. (2025). *A machine learning and network science approach to identifying corruption risks in public procurement*. arXiv. <https://arxiv.org/abs/2512.19491>^[24]

Propuesta Técnica TFM UNIR – Sopra Steria

Coviello, D., & Mariniello, M. (2020). *Corruption red flags in public procurement: New evidence from Italian calls for tenders*. SSRN. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3612661^[25]

Ocampo-Gutiérrez, F., et al. (2019). *Anomaly detection in public procurements using the Open Contracting Data Standard*. CEUR Workshop Proceedings. <https://ceur-ws.org/Vol-2369/short09.pdf>^[26]

Ng'ang'a, K. (2025). *A hybrid machine learning model for detecting and predicting procurement corruption*. Science Publishing Group. <https://www.sciencepublishinggroup.com/article/10.11648/j.mlr.20251002.14>^[27]

LangChain AI. (2024). *LangGraph: Build stateful, multi-actor applications with LLMs*. <https://github.com/langchain-ai/langgraph>^[28]

IBM Research. (2024). *Docling: An efficient and flexible document conversion library*. <https://github.com/DS4SD/docling>^[29]

BAAI. (2024). *BGE-M3: Multi-functionality, multi-linguality, multi-granularity text embeddings*. Hugging Face. <https://huggingface.co/BAAI/bge-m3>^[30]

Alibaba Cloud. (2024). *Qwen3: Technical report*. <https://huggingface.co/Qwen>^[31]

Mistral AI. (2025). *Mistral Small 3*. <https://mistral.ai>^[32]

Google Labs. (2026). *Stitch: AI-powered UI design tool*. <https://stitch.withgoogle.com>^[33]

Brooke, J. (1996). SUS: A quick and dirty usability scale. *Usability Evaluation in Industry*, 189(194), 4-7.^[34]

1. plantilla_grupal-3-2.docx
2. https://www.reddit.com/r/LocalLLaMA/comments/1psi4ot/building_an_autonomous_ai_auditor_for_iso/
3. https://sede.agenciatributaria.gob.es/Sede/Desarticulada_una_trama_de_fraude_en_la_contratacion_de_obra_publica_en_Cantabria.html
4. <https://arxiv.org/abs/2602.16731>
5. <https://arxiv.org/html/2602.16731v1>
6. <https://arxiv.org/abs/2512.19491>
7. <https://www.sciencepublishinggroup.com/article/10.11648/j.mlr.20251002.14>
8. <https://www.incibe.es/ed2026/estudio-instalacion-auditoria-modelos-LLM-locales>

Propuesta Técnica TFM UNIR – Sopra Steria

9. <https://ricg.org/wp-content/uploads/2023/01/Guide-to-identify-corruptions-risks-in-public-procurement-using-data-science.pdf>
10. <https://www.open-contracting.org/wp-content/uploads/2016/11/OCP2016-Red-flags-for-integrityshared-1.pdf>
11. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3612661
12. https://www.hacienda.gob.es/es-ES/GobiernoAbierto/Datos Abiertos/Paginas/licitaciones_plataforma_contratacion.aspx
13. <https://obcp.es/sites/default/files/2022-06/Rubén Martínez - Datos abiertos en el ámbito de la contratación.pdf>
14. <https://ceur-ws.org/Vol-2369/short09.pdf>
15. <https://data.open-contracting.org/en/publication/94>
16. <https://www.govtransparency.eu/opentender/>
17. https://www.govtransparency.eu/wp-content/uploads/2021/07/July-7-Horn_EEA_opentender_training_data.pdf
18. <https://eldoc.online/es/blog/local-llm-deployment-for-documents/>
19. <https://agentesinteligentes.es/ia-local-privacidad-datos/>
20. <https://www.quantumbabylon.org/noticias-y-ocio/implementacion-de-modelos-de-inteligencia-artificial-en-local-para-el-sector-sanitario-privacidad-control-y-criterio-clinico>
21. <https://www.promptlayer.com/research-papers/llms-supercharge-ocr-how-ai-automates-document-processing>
22. <https://articles.chatnexus.io/knowledge-base/compliance-and-audit-rag-systems-for-regulatory-documentation/>
23. <https://es.scribd.com/document/462218388/Temario-Tcos-Servicios-Generales-UCM-2019-FINAL-pdf>
24. https://asocex.es/wp-content/uploads/2025/06/107_125-Articulo-Requejo.pdf
25. <https://unstract.com/blog/llmwhisperer-best-ocr-for-data-entry/>
26. <https://www.auxiliobits.com/blog/rag-architecture-for-domain-specific-knowledge-retrieval-in-financial-compliance/>
27. <https://tesiunamdocumentos.dgb.unam.mx/ppt2002/0321363/0321363.pdf>
28. <https://www.muycomputerpro.com/2026/03/16/juan-jose-vazquez-legalitas-entrevista-alex>
29. <https://www.octaria.com/blog/what-are-advancements-in-ocr-technologies-in-q1-2025-using-llms>
30. <https://arxiv.org/html/2603.14170v1>
31. <https://aws.amazon.com/blogs/machine-learning/build-a-domain-aware-data-preprocessing-pipeline-a-multi-agent-collaboration-approach/>

Propuesta Técnica TFM UNIR – Sopra Steria

32. <https://www.llamaindex.ai/blog?tag=Multimodal>
33. <https://aclanthology.org/2025.realm-1.6.pdf>
34. <https://www.llamaindex.ai/blog/agentive-document-extraction>
35. <https://datos.gob.es/es/catalogo/l01241152-licitaciones>
36. <https://www.opengovpartnership.org/members/lithuania/commitments/lt0031/>
37. <https://interoperable-europe.ec.europa.eu/collection/eprocurement/document/spanish-government-eprocurement-platform-place>
38. <https://okdiario.com/economia/gobierno-alerta-hackeo-concursos-publicos-que-estafa-miles-euros-empresas-16389840>
39. https://www.jacobe.edu.mx/revista/numeros/numero21/6.Arosa-Daniel_et-al.pdf
40. <https://datos.gob.es/es/solicitud-de-datos/empresas-condenadas-por-fraude-en-licitaciones-publicas>
41. <https://data.europa.eu/data/datasets/ocds-appalti-ordinari-2024?locale=en>
42. <https://www.focuspiedra.com/hacienda-alerta-de-estafas-masivas-a-los-autonomos-que-optan-por-licitaciones-de-contratos-publicos/>
43. <https://datos.gob.es/en/catalogo/conjuntos-datos>
44. <https://www.gobierno.es/contratacion-explorador>
45. <https://oa.upm.es/id/file/1340027>
46. https://datos.gob.es/sites/default/files/doc/file/guia_publicacion_apis.pdf
47. <https://www.euskadi.eus/gobierno-vasco/-/2024/nueva-api-rest-sobre-la-plataforma-kontratazioa/>
48. https://opendatapre.portdebarcelona.cat/es/dataset/transparencia---contractes-majors/resource/2bb1dba6-6602-4196-96bf-554ed6aece44?view_id=1a599423-3b74-4b72-8770-910591f11469
49. <http://femp.femp.es/files/3580-1617-fichero/Guía Datos Abiertos.pdf>
50. http://essay.utwente.nl/104916/1/Peeters_MA_BMS.pdf